

Tarefa 1

Table of Contents

Tarefa 1 - Análise Exploratória de Dados	2
Tarefa 2 - Sessão Interativa de Pesquisa sobre Referências de Artigos	7

Tarefa 1 - Análise Exploratória de Dados

Introdução

Nesta tarefa, explorei um conjunto de dados contendo informações sobre dois grupos de participantes, denominados Grupo A e Grupo B. O meu objetivo principal foi compreender as características dos dados, identificar padrões e verificar se existem diferenças relevantes entre os grupos em relação a duas variáveis: número de passos diários (Steps) e índice de massa corporal (BMI).

Sobre os Dados

O conjunto de dados é composto por dois arquivos de texto formatados como CSV, cada um representando um grupo diferente de participantes. Ambos os arquivos possuem três colunas: um identificador único (ID), a quantidade de passos registrados em um período e o BMI do participante.

O Grupo A possui 865 participantes, enquanto o Grupo B conta com 921 participantes. Essa diferença no tamanho das amostras já é um ponto importante a considerar em eventuais comparações estatísticas futuras, embora não comprometa a análise exploratória realizada aqui.

Análise Descritiva

Grupo A

Ao calcular as estatísticas descritivas do Grupo A, observei que a média de passos diários ficou em torno de 8.997, com um desvio padrão de 3.407. Isso indica uma variabilidade considerável entre os participantes, uma vez que alguns registraram apenas 3.011 passos enquanto outros atingiram quase 15.000. A mediana de 9.075 está bem próxima da média, sugerindo uma distribuição relativamente simétrica para os passos.

Em relação ao BMI, a média foi de 26,02, com desvio padrão de 3,86. Os valores variaram de 12,8 (abaixo do peso) até 38,6 (obesidade grau I). A mediana de 25,9 praticamente coincide com a média, reforçando a simetria da distribuição.


Grupo B

O Grupo B apresentou resultados bastante semelhantes. A média de passos foi de 9.061, praticamente igual à do Grupo A, com um desvio padrão ligeiramente maior (3.493). A faixa de valores também foi similar, variando de 3.015 a 14.993 passos.

Para o BMI, a média foi de 25,88, praticamente idêntica ao Grupo A. No entanto, o desvio padrão foi um pouco maior (4,03), e o valor máximo atingiu 42,3, um ponto que chama atenção e que discuto adiante.

Visualizações


Distribuição de Passos



Steps Boxplot

O boxplot de passos mostra uma semelhança notável entre os dois grupos. As medianas estão praticamente alinhadas em torno de 9.000 passos, e a dispersão é muito parecida. Os dois grupos apresentam uma cauda superior mais longa, indicando que há mais participantes com altas contagens de passos do que com valores muito baixos. Não há outliers evidentes nesta variável, o que sugere que os valores extremos estão dentro de uma faixa esperada para o tipo de atividade monitorada.


Distribuição de BMI



BMI Boxplot

No boxplot de BMI, as distribuições também são bastante similares entre os grupos, com medianas em torno de 25,9, valor que se encontra na faixa de "sobrepeso" segundo classificações da OMS. No entanto, o Grupo B apresenta alguns outliers na parte superior, com o valor mais extremo atingindo 42,3. Esses casos representam participantes com obesidade grau II e mereceriam uma investigação mais aprofundada para entender se são erros de medição ou participantes com condições específicas.

Relação entre Passos e BMI



Steps vs BMI

O gráfico de dispersão que cruza passos com BMI é talvez a visualização mais reveladora. Nele, vejo que os pontos estão bastante dispersos, sem formar um padrão claro de correlação. Participantes com poucos passos apresentam BMIs variados, assim como aqueles com muitos passos. Essa dispersão indica que, pelo menos nestes dados, o número de passos diários por si só não parece ser um bom preditor do BMI.

Chama atenção que tanto no Grupo A quanto no Grupo B a nuvem de pontos tem uma forma bastante similar, reforçando a ideia de que os dois grupos são comparáveis em termos de comportamento e perfil.

Observações Adicionais

Alguns pontos que julguei relevantes destacar:

- A média de BMI de ambos os grupos está ligeiramente acima de 25, o que classifica a maioria dos participantes como "sobrepeso". Isso pode ser relevante para decisões sobre programas de saúde ou intervenções.
- A variabilidade nos passos é alta em ambos os grupos. Isso pode indicar que a população é bastante heterogênea em termos de hábitos de atividade física, com desde pessoas bastante sedentárias até muito ativas.

- A presença de outliers de BMI no Grupo B, especialmente o valor de 42,3, pode distorcer médias e outras medidas de tendência central caso não sejam tratados adequadamente em análises futuras.
- A ausência de correlação visível entre passos e BMI não significa necessariamente que não existe relação entre as variáveis, pode ser que ela seja fraca, não linear, ou que outros fatores (como dieta, idade, condições de saúde) tenham papel mais relevante.

Conclusão

De modo geral, a análise exploratória revelou que os dois grupos são bastante similares tanto em termos de atividade física quanto de composição corporal. Não há diferenças marcantes que indiquem que um grupo é significativamente diferente do outro. Os dados apresentam variabilidade considerável, o que é esperado em uma população diversa, e a relação entre passos e BMI não se mostrou forte o suficiente para drew conclusões simplistas.

Para uma análise mais aprofundada, seria recomendável aplicar testes estatísticos formais (como o teste t de Student para comparar médias ou o teste de Kolmogorov-Smirnov para comparar distribuições), além de considerar a inclusão de outras variáveis que possam explicar melhor o BMI dos participantes.

Tarefa 2 - Sessão Interativa de Pesquisa sobre Referências de Artigos

Introdução

Nesta tarefa, realizei uma sessão interativa de pesquisa na plataforma VALIS, conversando com o assistente Alan sobre dois artigos fundamentais na história do Aprendizado de Máquina: o artigo de McCulloch e Pitts (1943) e o artigo de Rosenblatt (1958). O objetivo foi compreender as contribuições principais de cada artigo, identificar os conceitos fundamentais que eles introduziram, explorar por que estes modelos não foram suficientes para avançar o ML mais adiante naquela época, e analisar quais insights ou capacidades importantes estavam faltando.

Link da conversa: <https://ai.valis.jala.university/conversations/3380e96f-9b61-42fc-852e-201fc0314a4b>

Artigo 1: McCulloch e Pitts (1943)

Contexto e Motivação

Comecei a conversa perguntando sobre as principais contribuições do artigo de McCulloch e Pitts de 1943. O Alan explicou que o artigo intitulado "A Logical Calculus of the Ideas Immanent in Nervous Activity" é considerado um dos textos mais fundamentais da história da computação e da inteligência artificial. McCulloch era neurofisiologista e Pitts era matemático, e a colaboração entre os dois resultou em uma visão revolucionária sobre como o cérebro poderia ser modelado matematicamente.

Principais Contribuições Identificadas

A primeira grande contribuição foi o primeiro modelo matemático de um neurônio biológico. Eles demonstraram que um neurônio pode ser abstraído como uma unidade lógica que recebe entradas, realiza uma soma ponderada e produz uma saída binária com base em uma função de limiar. Essa abstração era elegante e poderosa porque capturava a essência do funcionamento neural de forma que podia ser estudada formalmente.

A segunda contribuição foi a conexão entre neurônios e lógica proposicional. Eles mostraram que neurônios interconectados podem implementar operações lógicas fundamentais como AND, OR e NOT. Isso estabeleceu uma ponte direta entre biologia, lógica matemática e computação, algo que não existia antes.

A terceira contribuição foi a base para a teoria da computação. Construindo sobre as ideias de Alan Turing, McCulloch e Pitts demonstraram que redes de neurônios simples possuem enorme poder computacional, capazes de representar qualquer função computável. Isso foi fundamental para inspirar John von Neumann e Norbert Wiener no desenvolvimento de computadores e da cibernética.

A quarta contribuição foi a fundação das redes neurais artificiais. O neurônio de McCulloch-Pitts é considerado o ancestral direto dos neurônios artificiais modernos, inspirando o Perceptron de Rosenblatt e, posteriormente, as redes neurais profundas que usamos hoje.

Como o Neurônio Foi Modelado

Perguntei ao Alan como eles modelaram o neurônio artificial e qual era a base matemática utilizada. Ele explicou que o modelo era inspirado no neurônio biológico, onde os dendritos recebem sinais, o soma processa esses sinais e, se o sinal acumulado ultrapassar um limiar, o neurônio dispara.

A matemática era simples e elegante: primeiro somavam-se todas as entradas binárias recebidas, depois comparava-se essa soma com um limiar θ . Se a soma fosse maior ou igual ao limiar, a saída era 1 (o neurônio disparava). Caso contrário, a saída era 0. As entradas eram estritamente binárias e os pesos eram fixos, sendo o único parâmetro ajustável o limiar θ .

Operações Lógicas

Continuei investigando como os neurônios de McCulloch-Pitts realizam operações lógicas. O Alan mostrou que a mesma estrutura (soma ponderada + comparação com limiar) realiza operações diferentes simplesmente mudando θ e os pesos.

Para a operação AND, os pesos são iguais a 1 para todas as entradas e o limiar é igual ao número de entradas. Assim, o neurônio só dispara se todas as entradas forem 1. Para a operação OR, os pesos são iguais a 1, mas o limiar é 1, então qualquer entrada ativa o disparo. Para a operação NOT, utiliza-se um peso negativo (inibitório) que inverte a lógica da entrada.

A grande sacada é que qualquer função lógica pode ser construída a partir de combinações de AND, OR e NOT, o que significa que redes de neurônios MCP podem, em teoria, computar qualquer função booleana.

Conexão com Autômatos Finitos e Máquinas de Turing

Perguntei como o artigo conecta redes neurais com a teoria de autômatos finitos e máquinas de Turing. O Alan explicou que McCulloch e Pitts perceberam que redes desses neurônios se comportam como autômatos, sistemas que transitam entre estados em resposta a entradas. Marvin Minsky formalizou isso mais tarde com o teorema de que toda máquina de estados finitos pode ser mapeada para uma rede neural equivalente.

A conexão com máquinas de Turing se dá quando consideramos redes recorrentes. Siegelmann e Sontag provaram em 1993 que redes neurais recorrentes analógicas são Turing-completas, ou seja, podem simular qualquer Máquina de Turing. A intuição é que a ativação contínua dos neurônios pode codificar símbolos da fita nos dígitos decimais de um número real, simulando a memória infinita da fita.

Limitações do Modelo

Ao explorar as limitações, identifiquei que o modelo de McCulloch e Pitts tinha sérias restrições que impediram o avanço do ML. A principal era a ausência total de aprendizado. O limiar θ era definido manualmente pelo modelador, e o neurônio não aprendia a partir de dados, não ajustava pesos, não melhorava com a experiência. Para uma área cuja essência é aprender, isso era uma contradição fundamental.

Outra limitação eram as entradas e saídas estritamente binárias. O mundo real é contínuo, com temperaturas, preços e probabilidades, mas o modelo só aceitava valores 0 ou 1. Isso tornava impossível representar problemas com variáveis reais ou graduais.

O modelo também era limitado a problemas linearmente separáveis, ou seja, onde as classes podiam ser separadas por uma linha reta. O exemplo clássico que expôs isso foi o problema XOR, onde nenhuma linha reta consegue separar os resultados.

Além disso, os pesos eram fixos e todos os inputs excitatórios tinham o mesmo peso, não havendo como expressar que uma entrada é mais relevante que outra. A inibição das entradas inibitórias era absoluta, forçando a saída para 0 independentemente das outras entradas, e a estrutura da rede era estática, não mudando com o tempo.

Artigo 2: Rosenblatt (1958)

Contexto e Diferenças em Relação a McCulloch e Pitts

Avancei para o artigo de Rosenblatt de 1958, perguntando sobre suas principais contribuições e como ele difere do modelo anterior em termos de aprendizado. O Alan explicou que o artigo "The Perceptron: A Probabilistic Model for Information Storage and Organization in the Brain" foi publicado no Psychological Review, tornando as ideias acessíveis a um público mais amplo.

Principais Contribuições do Perceptron

A primeira grande contribuição foi um modelo probabilístico de aprendizado. Rosenblatt não propôs apenas um neurônio artificial, mas sim um modelo de como o cérebro pode armazenar e organizar informações, trazendo uma perspectiva probabilística que era inovadora para a época.

A segunda contribuição foram os pesos numéricos ajustáveis. Pela primeira vez, as conexões entre neurônios passaram a ter pesos com valores numéricos reais, e não apenas fixos. Isso significava que a importância de cada entrada poderia variar, algo fundamental para o aprendizado.

A terceira contribuição foi o algoritmo de aprendizado por correção de erros. Rosenblatt introduziu um mecanismo onde o modelo ajusta seus pesos automaticamente com base na diferença entre o resultado esperado e o resultado obtido. Em essência, quando o modelo erra, ele se ajusta para errar menos da próxima vez.

A quarta contribuição foi a estrutura em camadas. Rosenblatt organizou o Perceptron em três tipos de unidades: S (Sensory) que percebe o ambiente, A (Association) que processa internamente e R (Response) que gera a resposta. Isso antecipou conceitualmente a ideia de redes neurais em camadas.

Separação Estatística

Perguntei o que é a "separação estatística" e como ela foi usada no Perceptron. O Alan explicou que Rosenblatt formalizou a ideia de que um conjunto de dados é linearmente separável se existe um hiperplano que divide perfeitamente os exemplos de duas classes, sem que nenhum ponto fique do lado errado.

A palavra "estatística" vinha da visão probabilística de Rosenblatt. Para ele, o processo de aprendizado era probabilístico, inspirado na biologia dos neurônios. A separação estatística era a fundamentação matemática que dizia que padrões no mundo poderiam ser classificados com base em regularidades probabilísticas, não em regras rígidas.

A implicação prática era que se os dados são linearmente separáveis, o Perceptron pode aprendê-los. Se não são, como no XOR, o Perceptron falha por princípio. Essa limitação ficou famosa na crítica de Minsky e Papert em 1969.

Algoritmo de Aprendizado e Garantias Teóricas

Explorei como funciona o algoritmo de aprendizado do Perceptron e suas garantias teóricas. O Alan descreveu o processo como iterativo: apresenta-se um exemplo, calcula-se a saída atual, compara-se com o resultado esperado, e se houver erro, ajustam-se os pesos na direção que corrigiria o erro. É um ciclo de tentativa, erro e correção.

A garantia teórica mais poderosa era o Teorema de Convergência, que afirma que se os dados são linearmente separáveis, o algoritmo é garantido de encontrar um hiperplano separador em um número finito de atualizações. O número máximo de erros antes da convergência é limitado por $(R/\gamma)^2$, onde R é o raio do conjunto de dados e γ é a margem de separação.

Essa foi a primeira vez que um algoritmo de aprendizado tinha uma prova matemática rigorosa do seu comportamento. Não era apenas empírico, era provado. No entanto, se os dados não forem linearmente separáveis, o algoritmo cicla infinitamente, nunca convergindo.

Memória Distribuída

A última conceito que explorei foi a "memória distribuída" no contexto do Perceptron. O Alan explicou que Rosenblatt propôs que a memória do Perceptron é distribuída, no sentido de que qualquer associação pode fazer uso de uma grande proporção das células no sistema. A remoção de uma porção do sistema de associação não teria um efeito apreciável no desempenho de uma discriminação ou associação específica, mas começaria a aparecer como um déficit geral em todas as associações aprendidas.

Isso contrastava com a memória localizada, onde cada memória tem um endereço fixo. A analogia do holograma é perfeita: se você rasga um holograma ao meio, não perde metade da imagem, mas vê a imagem inteira com menos resolução. O dano é gradual e difuso, não catastrófico.

Rosenblatt estava fortemente influenciado por estudos neurológicos de Karl Lashley, que observou que ratos com porções do córtex cerebral removido não perdiam habilidades específicas abruptamente, mas o desempenho degradava proporcionalmente à

quantidade de córtex removido. Isso sugeriu que memórias não estavam armazenadas em locais específicos, mas distribuídas.

Síntese Comparativa

Insights que Estavam Faltando

Na parte final da conversa, perguntei ao Alan quais insights importantes estavam faltando para que o ML pudesse avançar de verdade. Ele organizou a análise em duas partes.

Para McCulloch e Pitts, os insights ausentes incluíam o fato de trabalharem apenas com entradas e saídas binárias, quando o mundo real é contínuo. Os pesos fixos significavam que não havia ideia de que pesos poderiam emergir de dados. A ausência de aprendizado era uma contradição fundamental. Não havia camadas intermediárias, apenas entrada direta para saída. A inibição absoluta era biologicamente simplista. O insight mais fundamental que faltava era ver o neurônio como um processador estatístico que aprende representações do mundo, e não apenas como uma porta lógica.

Para Rosenblatt, as limitações incluíam apenas uma camada de processamento, o que limitava a classificação a dados linearmente separáveis. O problema do XOR provou que o modelo tinha um teto computacional muito baixo. A ausência de função de ativação diferenciável tornava impossível aplicar cálculo de gradientes para treinar redes com múltiplas camadas. Não havia algoritmo para redes profundas, embora Rosenblatt soubesse que múltiplas camadas resolveriam o problema. O insight mais fundamental que faltava era o mecanismo de propagação do erro para camadas internas.

Soluções Desenvolvidas nos Anos 1970-1980

O Alan explicou que entre 1969 e 1986 foi uma das épocas mais dramáticas da ciência moderna. O livro "Perceptrons" de Minsky e Papert mergulhou o campo em um AI Winter, mas em paralelo, pesquisadores construíam as peças do quebra-cabeça.

A Regra de Hebb de 1949 propôs que neurônios que disparam juntos se ligam juntos, plantando a semente da ideia de que a força de uma conexão pode ser modificada com experiência. As funções de ativação contínuas e diferenciáveis, como a sigmoide, permitiram o cálculo de gradientes, essencial para o aprendizado. O Backpropagation, descrito por Paul Werbos em 1974 e popularizado por Rumelhart, Hinton e Williams em 1986, demonstrou que o erro na saída pode ser propagado de volta pela rede, camada por camada, permitindo que pesos internos aprendessem.

Influência nos Modelos Modernos

Quando perguntei como esses dois artigos influenciaram o desenvolvimento das redes neurais modernas e do deep learning, o Alan organizou a resposta em termos de herança estrutural.

De McCulloch e Pitts, herdamos o neurônio artificial como unidade base de qualquer rede neural moderna, a ideia de que cognição pode ser modelada matematicamente, e o prenúncio da Universal Approximation Theorem, que mostra que redes podem computar qualquer função lógica.

De Rosenblatt, herdamos os pesos ajustáveis por dados, que é o coração de todo modelo de ML, o aprendizado por correção de erro como essência do backpropagation, o paradigma de dados para aprendizado para generalização, que define o Machine Learning como campo, e a ideia primitiva de gradiente descendente, base das variantes modernas como Adam e SGD.

Conclusão

Através dessa sessão interativa com o Alan, desenvolvi uma compreensão profunda de como esses dois artigos moldaram o campo do Machine Learning. Cada limitação apontada se tornou um mapa para o próximo avanço, e a história mostra que o Deep Learning moderno não nasceu de uma epifania única, mas é o produto acumulado de décadas de insights parciais. A conversa me ajudou a entender que a evolução tecnológica frequentemente acontece quando limitações são identificadas e transformadas em oportunidades de pesquisa.