

Lab 1

Table of Contents

Atividade 1	2
Atividade 2	11

Atividade 1



Gitlab: https://gitlab.com/gustajesus/data-science/-/tree/main/labs/lab-1?ref_type=heads (https://gitlab.com/gustajesus/data-science/-/tree/main/labs/lab-1?ref_type=heads)

Fundamentos

Nesta atividade, trabalhei com o **Wisconsin Diagnostic Cancer Dataset**, um conjunto de dados amplamente utilizado em machine learning para classificação de câncer de mama. O dataset contém características computadas a partir de imagens digitalizadas de aspirados por agulha fina (FNA) de amostras de tecido mamário.

Sobre o Dataset

- 569 instâncias (pacientes)
- 30 características numéricas computadas dos núcleos celulares presentes nas imagens
- Classificação binária: Diagnóstico **Maligno (M)** ou **Benigno (B)**

Estrutura dos Dados

As 30 características são organizadas em três grupos de 10 medidas cada:

Grupo	Medidas
Mean (Média)	radius, texture, perimeter, area, smoothness, compactness, concavity, concave points, symmetry, fractal_dimension
SE (Erro Padrão)	radius, texture, perimeter, area, smoothness, compactness, concavity, concave points, symmetry, fractal_dimension
Worst (Pior/Máximo)	radius, texture, perimeter, area, smoothness, compactness, concavity, concave points, symmetry, fractal_dimension

As medidas descrevem propriedades geométricas e morfológicas dos núcleos celulares, como tamanho, forma e textura.

Descrição da Minha Análise

Realizei a análise exploratória usando Python com as bibliotecas **pandas**, **numpy**, **matplotlib** e **seaborn**. O notebook `wisconsin-cancer-analysis.ipynb` contém todo o código e análise completa que desenvolvi.

Resultados da Análise


1. Visão Geral dos Dados

O dataset possui **569 registros** e **33 colunas** (incluindo `id`, `diagnosis` e a coluna `Unnamed: 32` que foi removida por conter apenas valores nulos). Não há valores faltantes nas colunas de características.

2. Distribuição do Diagnóstico

A distribuição do diagnóstico é desbalanceada:

- **Benigno (B):** 357 casos (62.7%)
- **Maligno (M):** 212 casos (37.3%)




Distribuição do Diagnóstico

3. Distribuição das Variáveis


As variáveis foram analisadas separadamente por grupo:

Variáveis Mean (Média)




Histogramas Mean

Variáveis SE (Erro Padrão)



Histogramas SE


Variáveis Worst (Pior/Máximo)



Histogramas Worst

4. Matriz de Correlação

A matriz de correlação revela as relações entre todas as variáveis numéricas:




Observações importantes:

- Existe uma **alta correlação positiva** entre variáveis do mesmo grupo (ex: `radius_mean`, `perimeter_mean` e `area_mean` estão fortemente correlacionadas)
- As variáveis `_worst` tendem a ter correlações mais fortes com o diagnóstico

5. Correlação com o Diagnóstico

Após codificar o diagnóstico (M=1, B=0), identifiquei as **Top 10 correlações** com o diagnóstico maligno:


Feature	Correlação
concave points_worst	0.7936
perimeter_worst	0.7829
concave points_mean	0.7766
radius_worst	0.7765
perimeter_mean	0.7426
area_worst	0.7338
radius_mean	0.7300
area_mean	0.7090
concavity_mean	0.6964
concavity_worst	0.6596



Top 10 Correlações


6. Distribuição por Diagnóstico - Top Features

As variáveis com maior correlação mostram diferenças claras entre os diagnósticos:




Distribuição Top Features

7. Relações entre Features



Scatter Features

8. Boxplots por Diagnóstico



Boxplots Diagnóstico

Tabelas Estatísticas

Estatísticas Descritivas

Arquivo: `tabelas/wisconsin_estatisticas.csv`

Distribuição do Diagnóstico

Arquivo: `tabelas/wisconsin_distribuicao_diagnostico.csv`

Correlação com Diagnóstico

Minhas Conclusões

A análise exploratória que realizei do Wisconsin Diagnostic Cancer Dataset permitiu identificar diversas correlações entre as características dos núcleos celulares e o diagnóstico (Maligno ou Benigno):

1. **Concave points_worst** é a variável com maior correlação positiva com o diagnóstico maligno ($r = 0.79$)
2. Variáveis relacionadas ao **tamanho** dos núcleos celulares (perimeter, radius, area) mostram correlações fortes com o diagnóstico
3. As variáveis do grupo **_worst** (piores valores) são mais discriminativas que as médias
4. Existe uma **alta correlação entre variáveis do mesmo grupo**, sugerindo potencial para redução de dimensionalidade
5. As distribuições das principais características diferem significativamente entre casos benignos e malignos

Esses resultados são consistentes com o conhecimento médico: células malignas tendem a ser maiores, mais irregulares e com contornos mais concavos que células benignas.

Atividade 2

Fundamentos

Nesta atividade, trabalhei com o **Automobile MPG Dataset**, um conjunto de dados clássico de machine learning que contém informações de consumo de combustível em milhas por galão (MPG) e outros atributos para vários modelos de carros.

Sobre o Dataset

- **398 instâncias** (veículos)
- **8 atributos** incluindo MPG, cilindros, cilindrada, potência, peso, aceleração, ano do modelo e origem

Estrutura dos Dados

Atributo	Tipo	Descrição
mpg	float64	Consumo de combustível em milhas por galão
cylinders	int64	Número de cilindros do motor
displacement	float64	Cilindrada do motor (polegadas cúbicas)
horsepower	float64	Potência do motor (cavalo-fogão)
weight	int64	Peso do veículo (libras)
acceleration	float64	Tempo para acelerar de 0 a 60 mph (segundos)
model_year	int64	Ano do modelo (anos 70-80)
origin	int64	Origem do veículo (1: EUA, 2: Europa, 3: Japão)

Descrição da Minha Análise

Realizei a análise exploratória usando Python com as bibliotecas **pandas**, **numpy**, **matplotlib** e **seaborn**. O notebook `auto-mpg-analysis.ipynb` contém todo o código e análise completa que desenvolvi.

Resultados da Análise


1. Visão Geral dos Dados

O dataset possui **398 registros** e **9 colunas**. A coluna `horsepower` foi convertida de string para numérico, com valores nulos preenchidos pela mediana.

2. Estatísticas Descritivas

Atributo	Média	Desvio Padrão	Mínimo	Máximo
mpg	23.51	7.82	9.00	46.60
cylinders	5.45	1.70	3.00	8.00
displacement	193.43	104.27	68.00	455.00
weight	2970.42	846.84	1613	5140
acceleration	15.57	2.76	8.00	24.80
model_year	76.01	3.70	70.00	82.00

3. Distribuição das Variáveis Numéricas




Histogramas Variáveis

Observações:

- A variável `mpg` apresenta distribuição assimétrica à direita (positiva)
- A maioria dos carros tem entre 4 e 8 cilindros
- A distribuição do ano do modelo é relativamente uniforme


4. Distribuição de Cilindros



Distribuição Cilindros


A maioria dos veículos possui 4 cilindros (204 veículos), seguidos por 8 cilindros (103) e 6 cilindros (84).

5. Distribuição de Origem



- **EUA (1):** 249 veículos (62.6%)
- **Europa (2):** 70 veículos (17.6%)
- **Japão (3):** 79 veículos (19.8%)


6. Distribuição de MPG



Distribuição MPG

- **Média:** 23.51 MPG
- **Mediana:** 23.00 MPG
- A distribuição é **assimétrica à direita**, indicando que a maioria dos carros tem consumo moderado


7. Matriz de Correlação



8. Correlação com MPG

Identifiquei as correlações com MPG (consumo de combustível):

Feature	Correlação
model_year	+0.58
acceleration	+0.42
horsepower	-0.77
cylinders	-0.78
displacement	-0.80
weight	-0.83




Observações importantes:


- **Weight** (peso) tem a maior correlação negativa com MPG ($r = -0.83$), indicando que carros mais pesados consomem mais combustível

- **Displacement** (cilindrada) também tem forte correlação negativa ($r = -0.80$)
- **Model_year** tem correlação positiva moderada ($r = 0.58$), sugerindo que carros mais novos são mais eficientes

9. Relação entre Features e MPG




10. Relação por Origem



Os scatter plots revelam que:

- Carros de origem **européia e japonesa** tendem a ter maior MPG para o mesmo peso
- Existe uma **relação linear negativa** clara entre peso/potência e MPG

11. Boxplots por Variáveis Categóricas



Boxplots Categóricas

Descobertas:

- Carros com **menos cilindros** tendem a ter maior MPG
- A eficiência de combustível **melhorou significativamente** entre os anos 70 e 80
- Carros de origem **européia e japonesa** apresentam MPG médio superior aos carros americanos

Tabelas Estatísticas

Estatísticas Descritivas

Arquivo: `tabelas/auto-mpg_estatisticas.csv`

Correlação com MPG

Arquivo: `tabelas/auto-mpg_correlacao_mpg.csv`

Primeiras Linhas

Arquivo: `tabelas/auto-mpg_primeiras_linhas.csv`

Valores Nulos

Arquivo: `tabelas/auto-mpg_valores_nulos.csv`

Minhas Conclusões

A análise exploratória que realizei do Automobile MPG Dataset revelou padrões importantes sobre fatores que influenciam o consumo de combustível:

1. **Peso** é o fator que mais influencia negativamente o consumo de combustível ($r = -0.83$)
2. **Cilindrada** e **potência** também têm forte correlação negativa com MPG
3. O **ano do modelo** mostra melhoria na eficiência ao longo do tempo ($r = +0.58$)
4. A **origem do veículo** influencia o consumo, com carros europeus e japoneses sendo mais eficientes
5. Carros com **menos cilindros** tendem a ser mais econômicos
6. A distribuição de MPG é assimétrica à direita, com média de 23.51 e mediana de 23.0

Esses resultados são consistentes com o conhecimento da engenharia automotiva: veículos menores, mais leves e com motores de menor cilindrada tendem a ser mais eficientes em termos de consumo de combustível.